Inteligência Artificial Generativa

Professor

Marcelo Pita

Carga Horária

32 horas

Datas dos Encontros

30 e 31 de outubro

13 e 14 de novembro

04 e 05 de dezembro

18 e 19 de dezembro

Horário

Sexta: 14h às 17h40

Sábado: 9h às 12h40

Ementa do Curso

A disciplina introduz os fundamentos e aplicações da Inteligência Artificial Generativa, com foco especial em Modelos de Linguagem de Grande Porte (LLMs) e seu uso no setor público. São abordados os princípios conceituais que sustentam modelos generativos e suas aplicações. O curso aprofunda o uso de LLMs em Python e ferramentas low-code para tarefas de geração, análise e síntese de informação pública, explorando diversas técnicas, como engenharia de prompts, modelos de *embeddings*, *retrieval-augmented generation* (RAG) e customização (*fine tuning e contunued pretraining*) de modelos abertos. Também discute aspectos éticos, regulatórios e de governança da IA no Estado.

Objetivos do Curso

Este curso tem como objetivo geral capacitar o discente a compreender, projetar, implementar, avaliar e justificar o uso de sistemas de Inteligência Artificial Generativa no setor público, com base em critérios técnicos sólidos, análise de riscos e impacto sobre a tomada de decisão e a geração de valor público. Seus objetivos específicos são:

1. Compreender os fundamentos técnicos dos LLMs e da arquitetura Transformer;
2. Diferenciar abordagens de interação, recuperação de conhecimento e adaptação de modelos;
3. Projetar pipelines de IA Generativa adequados a contextos institucionais do setor público;
4. Avaliar criticamente riscos, limitações e implicações éticas e organizacionais da IA Generativa;
5. Justificar tecnicamente e institucionalmente a escolha entre prompting, RAG, CPT e fine tuning;
6. Desenvolver projeto de IA Generativa com aplicação de LLM.

Metodologia de Ensino

Aulas expositivas, estudos de caso, laboratórios práticos, desenvolvimento de projeto aplicado e discussões orientadas por critérios de decisão, risco e valor público.

Forma de Avaliação

A avaliação consistirá na execução, entrega e apresentação de um projeto final em

equipe consistindo no desenvolvimento de uma solução de IA Generativa com LLMs, obrigatoriamente acompanhado de relatório de projeto no formato de *artigo científico* (modelo IDP).

Distribuição dos pontos:

- **Proposta de projeto.** Peso: 1,0 ponto
  Data: 14/11/2026

- **Apresentação de projeto.** Peso: 3,0 pontos
  Data: 19/12/2026

- **Relatório de projeto (artigo científico).** Peso: 4,0 pontos
  Data: 08/01/2027

- **Códigos de projeto (Github público).** Peso: 2,0 pontos
  Data: 08/01/2027

Nota mínima para aprovação: 6,0.

Mini Currículo do Docente

MARCELO RODRIGO MACHADO PITA

Doutor em Ciência da Computação pela UFMG, com formação em Engenharia da Computação pela UPE e atuação em Biotecnologia pela UnB. É especialista e líder de projetos de IA no Serpro, com foco em modelos de linguagem, PLN e IA generativa, unindo pesquisa acadêmica e aplicação prática no setor público. Lattes: http://lattes.cnpq.br/ 2463256611461412.

Módulo I (dias 30 e 31/10/26)

Aula 1 (Fundamentos da IA Generativa e Modelos de Linguagem): Apresentação da disciplina. IA discriminativa vs. IA generativa. Modelos de linguagem: conceitos fundamentais. Evolução histórica: FFNs e RNNs. Mecanismo de Atenção e Arquitetura Transformer. LLMs, SLMs e DLMs. *System One Models.* Escala, emergência e limites semânticos dos LLMs.

Aula 2 (Engenharia de Prompt): Engenharia de Prompt como Interface de Interação. Zero-shot, few-shot e Chain-of-Thought. Chain-of-Density, Skeleton-of-Thought e Chain-of-Verification. Test-time compute. Prompting como habilidade tática e interface temporária. Riscos do uso exclusivo de prompting. Laboratório de engenharia de prompt.

Leituras Obrigatórias

JURAFSKY, Daniel; MARTIN, James H. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models*. 3. ed. [S. l.]: Online manuscript, 2026. Disponível em: https://web.stanford.edu/~jurafsky/slp3/. Acesso em: 5 fev. 2026.

ADAMS, Griffin et al. From sparse to dense: GPT-4 summarization with chain of density prompting. In: **CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING (EMNLP)**. *Proceedings…* [S. l.]: Association for Computational Linguistics, 2023.

BHATT, Bhuwan. *Chain-of-Verification (CoVe): reduce LLM hallucinations*. Learn Prompting, 27 set. 2024. Disponível em: https://learnprompting.org/docs/advanced/self_criticism/chain_of_verification. Acesso em: 5 fev. 2026.

DHULIAWALA, Shehzaad et al. *Chain-of-Verification reduces hallucination in large language models*. In: **FINDINGS OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS: ACL 2024**, Bangkok, Thailand, Aug. 11-16, 2024. p. 3563-3578. Association for Computational Linguistics, 2024. DOI: 10.18653/v1/2024.findings-acl.212. Disponível em: https://aclanthology.org/2024.findings-acl.212/. Acesso em: 5 fev. 2026.

KUKA, Valeriia. *Skeleton-of-Thought prompting: faster and efficient response generation*. Learn Prompting, 27 set. 2024. Disponível em: https://learnprompting.org/docs/advanced/decomposition/skeleton_of_thoughts. Acesso em: 5 fev. 2026.

RAZAVI, Amirhossein et al. *Benchmarking prompt sensitivity in large language models*. In: **EUROPEAN CONFERENCE ON INFORMATION RETRIEVAL (ECIR 2025)**. *Advances in Information Retrieval*. [S. l.]: Springer, 2025. p. 303–313. DOI: 10.1007/978-3-031-88714-7_29.

WEI, Jason et al. *Emergent abilities of large language models*. arXiv:2206.07682 [cs.CL], 15 jun. 2022. DOI: 10.48550/arXiv.2206.07682. Disponível em: https://arxiv.org/abs/2206.07682. Acesso em: 5 fev. 2026.

SCHÜLE, Martin. *On the semantics of large language models*. *Intellectica*, n. 81, p. 15-36, fev. 2025. Association pour la Recherche Cognitive. Disponível em: https://digitalcollection.zhaw.ch/handle/11475/32875. Acesso em: 5 fev. 2026.

Módulo II (dias 13 e 14/11/26)

Aula 3 (Retrieval-Augmented Generation (RAG)): Representação semântica e Embeddings. Busca semântica e bancos de dados vetoriais. Estratégias de chunking. Re-ranking e expansão de consultas. Arquitetura e stack de RAG (LLM, framework, banco vetorial e embeddings). RAG como estratégia institucional: auditabilidade, versionamento e risco jurídico. Laboratório de RAG.

Aula 4 (Sistemas Baseados em Agentes (Agentic AI)): Agentes baseados em LLM. Tool use e Model Context Protocol (MCP). Sistemas multiagente. Tecnologias e frameworks de agentes. Limites da autonomia de agentes e riscos para governança pública. Laboratório de Agentic AI.

Leituras Obrigatórias

ANTHROPIC. *Model Context Protocol (MCP) specification*. [S. l.]: Anthropic, 2024. Disponível em: https://docs.anthropic.com/en/docs/mcp (acesso em: 5 fev. 2026).

SAID, Adil. *RAG in practice: exploring versioning, observability, and evaluation in production systems*. Towards AI, 28 ago. 2025. Disponível em: https://towardsai.net/p/artificial-intelligence/rag-in-practice-exploring-versioning-observability-and-evaluation-in-production-systems. Acesso em: 5 fev. 2026.

DEENE, Joris. *Can a RAG system reduce the AVG risks of your corporate AI?* ICT Rechtswijzer, s.d. Disponível em: https://www.ictrechtswijzer.be/en/can-a-rag-system-reduce-the-gdpr-risks-of-your-enterprise-ai/. Acesso em: 5 fev. 2026.

JURAFSKY, Daniel; MARTIN, James H. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models*. 3. ed. [S. l.]: Online manuscript, 2026. Disponível em: https://web.stanford.edu/~jurafsky/slp3/. Acesso em: 5 fev. 2026.

LEI, Yiming et al. *Large language model agents: a comprehensive survey on architectures, capabilities, and applications*. *Preprints.org*, v. 2025, preprint submitted 23 dez. 2025, posted 24 dez. 2025. Disponível em: https://www.preprints.org/manuscript/202512.2119. Acesso em: 5 fev. 2026.

SINGH, Pankaj. *8 types of chunking for RAG systems*. Analytics Vidhya, 04 abr. 2025. Disponível em: https://www.analyticsvidhya.com/blog/2025/02/types-of-chunking-for-rag-systems/. Acesso em: 6 fev. 2026.

LI, Minghan et al. *Query expansion in the age of pre-trained and large language models: a comprehensive survey*. arXiv:2509.07794 [cs.IR], 09 set. 2025. Disponível em: https://arxiv.org/abs/2509.07794. Acesso em: 6 fev. 2026.

RUSSELL, Stuart; NORVIG, Peter. *Inteligência artificial: uma abordagem moderna*. 3. ed. Rio de Janeiro: Elsevier, 2013.

JADHAV, Bhushan. *LLM Agents: A Technical Guide and Practical Tips*. Aisera, s.d. Disponível em: https://aisera.com/blog/llm-agents/. Acesso em: 4 fev. 2026

Leituras Complementares

TAYLOR, Josh. *What is Moltbook? The strange new social media site for AI bots*. The Guardian, US edition, 2 fev. 2026. Disponível em: https://www.theguardian.com/ technology/2026/feb/02/moltbook-ai-agents-

Leituras Complementares

social-media-site-bots-artificial-intelligence. Acesso em: 4 fev. 2026.

Módulo III (dias 04 e 05/12/26)

Aula 5 (Continued Pre-Training (CPT)): Ciclo de vida do treinamento de LLMs. Objetivos e técnicas de CPT. Custos computacionais e institucionais. CPT como estratégia de infraestrutura cognitiva. Quando CPT é justificável no setor público. Laboratório de CPT.

Aula 6 (Fine Tuning e Alinhamento de LLMs): Fine tuning supervisionado. LoRA e QloRA. Knowledge distillation. Alinhamento: RLHF, DPO e GRPO. Escolha entre prompting, RAG, FT e CPT sob critérios de risco, custo e impacto. Laboratório de fine tuning.

Leituras Obrigatórias

BELCIC, Ivan; STRYKER, Cole. *RAG vs. fine-tuning vs. prompt engineering*. IBM Think, 2024. Disponível em: https://www.ibm.com/think/topics/rag-vs-fine-tuning-vs-prompt-engineering. Acesso em: 5 fev. 2026.

ERICKSON, Jeffrey. *RAG vs. Fine-Tuning: how to choose*. Oracle ASEAN, 21 nov. 2024. Disponível em: https://www.oracle.com/asean/artificial-intelligence/generative-ai/retrieval-augmented-generation-rag/rag-fine-tuning/. Acesso em: 5 fev. 2026.

ELHADY, Ahmed; AGIRRE, Eneko; ARTETXE, Mikel. *Emergent abilities of large language models under continued pre-training for language adaptation*. In: **ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS (ACL 2025)**, Vienna, Austria, Jul. 2025. *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Stroudsburg, PA: Association for Computational Linguistics, 2025. p. 32174–32186. DOI: 10.18653/v1/2025.acl-long.1547. Disponível em: https://aclanthology.org/2025.acl-long.1547/. Acesso em: 6 fev. 2026.

DETTMERS, Tim; PAGNONI, Artidoro; HOLTZMAN, Ari; ZETTLEMOYER, Luke. *QLoRA: Efficient finetuning of quantized large language models*. arXiv:2305.14314 [cs.LG], 23 mai. 2023. Disponível em: https://arxiv.org/abs/2305.14314. Acesso em: 6 fev. 2026.

FANG, Liang; YU, Xin; CAI, Jian; CHEN, Yan; WU, Shuo; LIU, Zhiyong; YANG, Zhi; LU, Hai; GONG, Xing; LIU, Yifan; MA, Tian; RUAN, Wei; ABBASI, Ali; ZHANG, Jian; WANG, Tao; LATIF, Ehsan; LIU, Wei; ZHANG, Wei; KOLOURI, Soroush; ZHAI, Xiaoming; ZHU, Dong; ZHONG, Wei; LIU, Tao; MA, Peng. *Knowledge distillation and dataset distillation of large language models: emerging trends, challenges, and future directions*. *Artificial Intelligence Review*, v. 59, n. 1, art. 17, 20 nov. 2025. DOI: 10.1007/s10462-025-11423-3. Disponível em: https://link.springer.com/article/10.1007/s10462-025-11423-3. Acesso em: 6 fev. 2026.

RAHEJA, Tarun; POCHHI, Nilay. *From RLHF to direct alignment: a theoretical unification of preference learning for large language models*. arXiv:2601.06108 [cs.CL], 03 jan. 2026. Disponível em: https://arxiv.org/abs/2601.06108. Acesso em: 6 fev. 2026.

Módulo IV (dias 18 e 19/12/26)

Aula 7 (Avaliação, Segurança e Governança da IA Generativa): Avaliação de LLMs. Métricas técnicas e métricas institucionais. Prompt injection e segurança de sistemas generativos. Governança da IA Generativa no setor público. *Artificial General Intelligence*.

Aula 8 (Projeto Aplicado): Apresentação dos projetos finais, com análise crítica das soluções propostas e discussão coletiva sobre riscos, limitações e impacto público.

Leituras Obrigatórias

LEE, Ro Woon et al. Vulnerability of large language models to prompt injection when providing medical advice. *JAMA Network Open*, v. 8, n. 12, e2549963, 19 dez. 2025. DOI: 10.1001/jamanetworkopen.2025.49963. Disponível em: https://jamanetwork.com/journals/jamanetworkopen/fullarticle/2842987. Acesso em: 5 fev. 2026.

CHANG, Yupeng et al. *A survey on evaluation of large language models*. *ACM Transactions on Intelligent Systems and Technology*, 2024. DOI:10.1145/3641289.

TEIXEIRA, Raphael Lobato Collet Janny. Diretrizes Ético-Jurídicas para o Design e Uso de Inteligência Artificial na Administração Pública. *In*: WORKSHOP SOBRE AS IMPLICAÇÕES DA COMPUTAÇÃO NA SOCIEDADE (WICS), 4. , 2023, João Pessoa/PB. Anais do IV Workshop sobre as Implicações da Computação na Sociedade. Porto Alegre: Sociedade Brasileira de Computação, 2023 . p. 123-130. ISSN 2763-8707. DOI: https://doi.org/10.5753/wics.2023.229812.

PEREIRA FILHO, Nivanildo; LIMA, Rogério de Araújo. Governança algorítmica e políticas públicas: desafios éticos e impactos da inteligência artificial na tomada de decisão governamental. *RECIMA21 – Revista Científica Multidisciplinar*, v. 6, n. 1, 2024. DOI: https://doi.org/10.47820/recima21.v6i1.6051.

MINISTÉRIO DA GESTÃO E DA INOVAÇÃO EM SERVIÇOS PÚBLICOS; SECRETARIA DE GOVERNO DIGITAL; DIRETORIA DE INFRAESTRUTURA DE DADOS; COORDENAÇÃO-GERAL DE FOMENTO DA INTELIGÊNCIA ARTIFICIAL. Inteligência artificial generativa no serviço público: definições, usos e boas práticas. Brasília, 2025. Disponível em: https://www.gov.br/governodigital/pt-br/infraestrutura-nacional-de-dados/inteligencia-artificial-1/ia-generativa-no-servico-publico.pdf. Acesso em: 9 fev. 2026.

MINISTÉRIO DA CIÊNCIA, TECNOLOGIA E INOVAÇÃO (MCTI); CONSELHO NACIONAL DE CIÊNCIA E TECNOLOGIA (CCT). Plano IA para o Bem de Todos: proposta de plano brasileiro de inteligência artificial 2024–2028. Brasília, 2024. Disponível em: https://www.gov.br/mcti/pt-br/acompanhe-o-mcti/noticias/2024/07/plano-brasileiro-de-ia-tera-supercomputador-e-investimento-de-r-23-bilhoes-em-quatro-anos/ia_para_o_bem_de_todos.pdf. Acesso em: 9 fev. 2026.